

Metodologias Experimentais em Informática

Introdução ao método experimental:

Porque precisamos de experimentar:

- Investigadores: para validar hipóteses, modelos e confirmar teorias.
- Engenheiros: para afinar sistemas, para comparar e escolher entre as diferentes opções nos projetos e para verificar se os requisitos ou as especificações são atendidas.

Planeamento de experiências:

O objetivo é projetar e realizar experiências válidas que permitam boas decisões técnicas.

Ideia base: introduzir alterações controlados nas variáveis de entrada, a fim de estudar o seu efeito sobre as variáveis observadas e obter o máximo de informações sobre as relações causa e efeito.

Etapas:

1. Declaração do problema.
2. Identificar as variáveis (dependentes são as variáveis de saída e as independentes são as variáveis de entrada que podem ser alteradas).
3. Gerar a hipótese (descrever as relações entre as variáveis de entrada e as variáveis de saída).
4. Definir o cenário experimental.
5. Desenvolver ferramentas e procedimentos para a experiência.
6. Executar a experiência e recolher dados.
7. Realizar a análise dos dados.
8. Tirar conclusões (muitas vezes volta-se ao início do processo).

Medições:

Métricas de desempenho:

- Speedup: $\beta = T_1/T_2$, o sistema 2 é β vezes mais rápido/lento que o sistema 1.
- Mudança relativa: $\Delta = (T_1 - T_2)/T_2 = \beta - 1$, o sistema 2 é $\Delta\%$ mais rápido/lento que o sistema 1.

Métricas de velocidade:

- Throughput: número de eventos completados num intervalo de tempo.
- Speedup: $\beta = R_2/R_1$, o sistema 2 é β vezes mais rápido/lento que o sistema 1.
- Mudança relativa: $\Delta = (R_2 - R_1)/R_1 = \beta - 1$, o sistema 2 é $\Delta\%$ mais rápido/lento que o sistema 1.

Propriedades para caracterizar as métricas:

- Linearidade: se o valor da métrica for modificado, o desempenho da máquina deve mudar na mesma proporção.
- Confiabilidade: uma métrica de desempenho é confiável, se um sistema A supera sempre o sistema B quando os valores correspondentes da métrica para ambos os sistemas indicam que o sistema A deva superar o sistema B.
- Repetibilidade: uma métrica de desempenho é repetível se o mesmo valor da métrica é obtido a cada vez que a mesma experiência é realizada.
- Consistência: uma métrica é consistente se tiver o mesmo valor num sistema diferente.

Incertezas:

Se repetirmos uma medição iremos obter resultados ligeiramente diferentes. Dois tipos de incertezas:

- Incertezas aleatórias: as variações nas medições ocorrem sem um padrão previsível.
- Incertezas sistémicas: as variações que causam que o valor medido seja menor ou maior que o valor exato.

Modelo de erros gaussiano:

O valor medido para X pode ser $X + E$ ou $X - E$ com a mesma probabilidade.

Introdução á interferência:

População: é um conjunto de entidades com alguma característica em comum.

Amostra: representa um subconjunto de uma população.

Distribuição normal:

É uma distribuição de probabilidade contínua com dois parâmetros μ e σ . Permite calcular a probabilidade num dado intervalo.

A distribuição normal pode ser transformada para a distribuição normal standard pela fórmula $Z = (x - \mu)/\sigma$.

Exemplo: para $\mu = 6$ e $\sigma = 4/5$, $P(4 \leq X \leq 5) \Leftrightarrow P(-2.45 \leq Z \leq -1.25) = 9.94\%$

A probabilidade associada à distribuição normal padrão está tabulada.

Calcular intervalos de confiança:

Cálculo de intervalos de confiança:

$x \pm z_{1-\alpha/2} \times \frac{s}{\sqrt{n}}$, para n (número de amostras) ≥ 30

$h = t_{n-1, 1-\alpha/2} \times \frac{\sigma}{\sqrt{n}}$, para $n < 30$

Intervalo de confiança para a diferença entre médias:

É usado para estimar a diferença entre as médias de duas populações.

Amostras independentes: se a seleção da primeira amostra não alterar a seleção da segunda amostra.

$$s_p = \sqrt{\frac{(n_1 - 1)s_1^2}{n_1} + \frac{(n_2 - 1)s_2^2}{n_2}}$$

$(\bar{x}_1 - \bar{x}_2) \pm z_{1-\alpha/2} \times s_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}$, se ambos os grupos tem $n \geq 30$

$(\bar{x}_1 - \bar{x}_2) \pm t_{n_1+n_2-2, 1-\alpha/2} \times s_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}$, se pelo menos um grupo tem $n < 30$

Amostras dependentes: se para cada observação numa amostra existe uma outra observação correspondente na outra.

$\bar{x}_D \pm z_{1-\alpha/2} \times \frac{s_D}{\sqrt{n}}$, para $n \geq 30$

$\bar{x}_D \pm t_{n-1, 1-\alpha/2} \times \frac{s_D}{\sqrt{n}}$, para $n < 30$

Proporções:

$\mu_p = p$, média $\sigma_p = \sqrt{\frac{p(1-p)}{n}}$, desvio padrão

Intervalo de confiança para a proporção:

$\bar{p} \pm z_{1-\alpha/2} \times \sqrt{\frac{\bar{p}(1-\bar{p})}{n}}$ se $\min(n\bar{p}, n(1-\bar{p})) > 5$

Intervalo de confiança para a diferença entre proporções:

$(\bar{p}_1 - \bar{p}_2) \pm z_{1-\alpha/2} \times \sqrt{\frac{\bar{p}_1(1-\bar{p}_1)}{n_1} + \frac{\bar{p}_2(1-\bar{p}_2)}{n_2}}$ se $\min(n_1\bar{p}_1, n_1(1-\bar{p}_1), n_2\bar{p}_2, n_2(1-\bar{p}_2)) > 5$

Teste de hipóteses:

Hipótese:

- É uma proposta de explicação para um determinado fenómeno.
 - É uma suposição sobre a eficiência de um dado componente/sistema.
- Uma hipótese requer avaliação para poder ser considerada verdadeira.

Caraterização de uma hipótese:

- Tópico: área de interesse onde a dificuldade a ser resolvida está incluída.
Exemplo: qualidade do código (ausência de bugs) produzido pelos programadores.
- Problema: é o objeto de estudo, pressupõe perguntas claras que formulam o problema a ser resolvido. Exemplo: se o método utilizado para o desenvolvimento do software está relacionado com o número de bugs.
- Hipótese: resposta provisória à pergunta, ou seja se a hipótese for confirmada, a resposta é considerada correta (para um determinado grau de certeza). Exemplo: o desenvolvimento do software utilizando o método A produz menos bugs que o método B.

Etapas dos testes de hipóteses:

1. Estado da hipótese a ser testada:

- Hipótese nula (H_0): é uma afirmação sobre um parâmetro da população (por exemplo a média da população) que se presume ser verdadeiro.
- Hipótese alternativa (H_1): é uma afirmação que contradiz a hipótese nula.

2. Selecionar o critério de decisão:

Definir um critério (5%), significa indicar o nível de significância para o teste.

3. Calcular os testes estatísticos:

Escolher uma amostra aleatória da população e medir a média da amostra.

O teste estatístico é uma fórmula para determinar se a hipótese nula é verdadeira.

$$Z_c = \frac{M - \mu}{\sigma / \sqrt{n}}$$

M - média da amostra, μ - média da população

4. Tomar uma decisão:

O valor da estatística de teste (Z_c) é a chave para tomar uma decisão sobre a hipótese nula. Se $P < 5\%$ rejeita-se a hipótese nula, se $P > 5\%$ mantêm-se a hipótese nula.

Medir o tamanho de um efeito:

$$\text{Cohen's } d = \frac{M - \mu}{\sigma}$$

M - média da amostra, μ - média da população,
 σ - desvio padrão da população.

Efeitos: pequeno: $|d| < 0.2$, médio: $0.2 < |d| < 0.8$, grande: $|d| > 0.8$

Se o valor de d é negativo, o efeito deslocou abaixo da média da população.

Teste T:

Segue a distribuição T-Student. É utilizado quando o número de amostras é < 30 .

- Uma amostra: utilizado para comparar uma média de uma amostra com a média de uma população conhecida. (graus de liberdade: $df = n - 1$)

$$t_c = \frac{\bar{x} - \mu}{s / \sqrt{n}}$$

\bar{x} - média da amostra, μ - média da população,
 s - desvio padrão da amostra, n - número de elementos da amostra

- Duas amostras independentes: utilizado para comparar duas amostras.

(graus de liberdade: $df = n_1 + n_2 - 2$)

$$t = \frac{\bar{x}_1 - \bar{x}_2}{S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \quad S_p = \sqrt{\frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2}}$$

- Duas amostras dependentes: utilizado para comparar duas amostras.

(graus de liberdade: $df = n - 1$)

$$t = \frac{\bar{x}_D - \mu}{\frac{s_D}{\sqrt{n}}} \quad \begin{array}{l} \bar{x}_D - \text{m\u00e9dia das diferen\u00e7as entre as duas amostras,} \\ s_D - \text{desvio padr\u00e3o das diferen\u00e7as} \end{array}$$

Testes n\u00e3o param\u00e9tricos:

Os testes de hip\u00f3teses n\u00e3o param\u00e9tricos s\u00e3o usados quando:

- Os dados t\u00eam um ranking e nenhuma interpreta\u00e7\u00e3o num\u00e9rica \u00e9 poss\u00edvel.
- Estamos interessados em um par\u00e2metro da popula\u00e7\u00e3o para o qual a distribui\u00e7\u00e3o \u00e9 desconhecida (m\u00e9dia, mediana).

An\u00e1lise da vari\u00e2ncia:

Utilizada quando temos mais de duas amostras para comparar. Por exemplo: qual \u00e9 o impacto do tamanho dos elementos no tempo de ordenamento.

O objetivo \u00e9 testar se a diferen\u00e7a entre as m\u00e9dias das v\u00e1rias amostras \u00e9 significativa. ANOVA pode fazer isso.

ANOVA com um fator:

Testa as hip\u00f3teses seguintes:

$H_0: \mu_1 = \mu_2 = \mu_3 = \dots = \mu_k$ (todas as m\u00e9dias dos grupos s\u00e3o iguais)

H_1 : nem todas as m\u00e9dias dos grupos s\u00e3o iguais.

N\u00e3o indica quais \u00e9 que diferem, para isso \u00e9 preciso acompanhar com compara\u00e7\u00f5es m\u00faltiplas (testes post-hoc, quando a hip\u00f3tese H_0 \u00e9 rejeitada).

Tabela ANOVA:

\u00c9 um resumo de todos os elementos necess\u00e1rios para o c\u00e1lculo do P value.

ANOVA etapas:

- Formula\u00e7\u00e3o de hip\u00f3teses (H_0 e H_1).
- Calcular o teste estat\u00edstico (preenchimento da tabela ANOVA).
- Obter o P value (est\u00e1 na tabela ANOVA).
- Tomar uma decis\u00e3o (se o P value $< \alpha$ rejeita-se a hip\u00f3tese H_0).

An\u00e1lise de vari\u00e2ncia com 2 fatores:

Utilizada para testar a igualdade de duas ou mais m\u00e9dias populacionais quando duas vari\u00e1veis independentes s\u00e3o utilizados (fator A e fator B).

ANOVA com 2 fatores testa 3 hip\u00f3teses simultaneamente:

- Nenhuma diferen\u00e7a nas m\u00e9dias devido ao fator A - $H_0^A \mu_1 = \mu_2 = \dots = \mu_a$
- Nenhuma diferen\u00e7a nas m\u00e9dias devido ao fator B - $H_0^B \mu_1 = \mu_2 = \dots = \mu_b$
- Nenhuma intera\u00e7\u00e3o dos fatores A e B - $H_0^{AB}: \forall(i,j): \gamma_{ij}$

Regressão linear:

Um modelo de regressão linear representa a relação entre uma variável y e uma variável x . Exemplo: o tempo de resposta de um servidor web com o aumento do número de pedidos.

Forma de um modelo de regressão linear:

$y = a + bx$, onde x é a variável de entrada, y é a resposta de saída prevista e a e b são os parâmetros de regressão que queremos estimar a partir de um conjunto de medições.

Correlação:

O coeficiente de determinação r^2 dá a fração de variação total explicada pelo modelo de regressão. Se existir uma relação perfeita entre a entrada e a saída então $r^2 = 1$.

Transformações:

Transformar os dados não lineares em uma forma linear:

- Regressão linear padrão: $y = a + bx$, $\hat{y} = a + bx$
- Modelo exponencial: $\ln(y) = a + bx$, $\hat{y} = ab^x$
- Modelo quadrático: $\sqrt{y} = a + bx$, $\hat{y} = (a + bx)^2$
- Modelo recíproco: $1/y = a + bx$, $\hat{y} = 1/(a + bx)$
- Modelo logarítmico: $y = a + b \cdot \ln(x)$, $\hat{y} = a + b \cdot \ln(x)$

Experiências com pessoas:

Áreas de aplicação:

- Testes de usabilidade (como é que as pessoas usam os sistemas).
- Avaliação do software ou produto no mercado.

Técnicas experimentais:

- Observação e análise de dados: ver como os utilizadores se comportam.
- Experiências controladas: ver como os utilizadores realizam tarefas predefinidas.
- Entrevistas e questionários: tentar entender as preferências e necessidades dos utilizadores.

Experiências controladas com utilizadores (etapas num estudo típico):

1. Definir os objetivos do sistema ou o módulo sob avaliação.
2. Criar um conjunto de tarefas a fim de atender a esses objetivos.
3. Escolher os testadores.
4. Observá-los a executar as tarefas.

Definir as tarefas para os testes de usabilidade:

- Fazer uma lista de tarefas e avaliá-las pela importância numa escala de 1 a 6.
- Definir os objetivos.
- Ser específico e claro sobre o que queremos que o utilizador faça.
- Criar uma sequência razoável.
- Evitar o uso de palavras que aparecem na interface.

Aspetos experimentais:

- Medir o tempo para executar as diferentes tarefas.
- Gravar em vídeo para análise posterior.
- Recolher informações sobre a experiência do testador.